

Mineração de Métricas DORA em Repositórios Open-Source: Quanto Podemos Confiar nas Aproximações?

Arthur Lara Panzera¹, Felipe Augusto Pereira¹, Gabriel Reis Lebron de Oliveira¹

¹Curso de Engenharia de Software – PUC Minas
Belo Horizonte – MG – Brasil

arthurpanzera@outlook.com, felipeaps0918@gmail.com, reislebron@gmail.com

Abstract. *DORA metrics (deployment frequency, lead time for changes, change failure rate and failed deployment recovery time) are the industry standard for measuring software delivery performance. GitHub, however, records neither production deployments nor production failures, so these metrics can only be approximated from releases, commits and CI workflow runs. This paper mines DORA metrics from popular open-source repositories that use GitHub Actions, validates the automatic criteria against human judgment, and measures how much each repository's DORA classification depends on the chosen operational definition.*

Resumo. *As métricas DORA (frequência de deploy, lead time de mudanças, taxa de falha de mudanças e tempo de recuperação) são o padrão de mercado para medir o desempenho de entrega de software. O GitHub, porém, não registra deploys nem falhas em produção, de modo que essas métricas só podem ser aproximadas a partir de releases, commits e execuções de CI. Este trabalho minera as métricas DORA de repositórios open-source populares que usam GitHub Actions, valida os critérios automáticos contra o julgamento humano e mede o quanto a classificação DORA de cada repositório depende da definição operacional escolhida.*

1. Introdução

Medir o desempenho de entrega de software é uma preocupação antiga da Engenharia de Software. Nos últimos anos, as métricas propostas pelo programa DORA (*DevOps Research and Assessment*), popularizadas pelo livro *Accelerate* [Forsgren et al. 2018] e revisadas anualmente pelos relatórios *Accelerate State of DevOps* [DORA 2024], tornaram-se o padrão de mercado para esse fim. Elas avaliam duas dimensões: a *velocidade*, por meio da frequência de deploy (*deployment frequency*) e do tempo entre um commit e sua entrega em produção (*lead time for changes*), e a *estabilidade*, por meio da proporção de deploys que causam falha (*change failure rate*, CFR) e do tempo para se recuperar delas (*failed deployment recovery time*) [DORA a]. Em 2024, o DORA acrescentou uma quinta métrica, a *deployment rework rate* [DORA b].

Essas métricas foram concebidas para equipes que operam serviços em produção e são, em geral, coletadas por questionários ou por ferramentas internas das organizações. Repositórios open-source oferecem uma oportunidade de medi-las em larga escala e com dados públicos, mas impõem um obstáculo: o GitHub não registra “deploys em produção” nem “falhas em produção”. O que existe são *releases*, *commits* e execuções de *workflows*

de integração contínua. Qualquer cálculo das métricas DORA nesse contexto depende, portanto, de *proxies*: uma release publicada é tomada como um deploy, e uma execução de CI que falhou é tomada como uma falha. Esses proxies podem enganar. Uma biblioteca que publica uma release por mês não está colocando nada em produção; quem o faz são seus usuários.

Este trabalho minera as métricas DORA de repositórios open-source populares (com mais de 1.000 estrelas) que usam GitHub Actions, em uma janela de observação de 12 meses (de 1º de outubro de 2025 a 30 de setembro de 2026). Além de calcular as métricas, o estudo questiona a confiabilidade dos próprios valores obtidos: os critérios automáticos são comparados com o julgamento de três avaliadores humanos sobre uma amostra de 60 repositórios, e uma análise de sensibilidade mede o quanto a classificação DORA de cada repositório muda quando a definição operacional da métrica muda. A pergunta deixa de ser apenas “qual é o valor da métrica?” e passa a ser também “o quanto podemos confiar nesse valor?”.

O estudo é guiado pelas sete questões de pesquisa (RQs) a seguir. Para cada uma, registramos uma hipótese informal, isto é, o que esperamos encontrar e por quê. As hipóteses foram escritas **antes** da coleta e da análise dos dados, para que a comparação com os resultados, feita na Seção 4, não seja influenciada por eles.

RQ1. Qual a frequência de deploys dos repositórios populares que usam CI/CD?

Hipótese H1: esperamos uma mediana entre uma release por mês e uma release por semana, o que corresponde à faixa *Medium* da tabela de referência, com distribuição fortemente assimétrica à direita. Projetos open-source costumam agrupar mudanças em versões planejadas, e muitos deles são bibliotecas, cujo ciclo de publicação é mais lento que o de serviços. Esperamos poucos repositórios *Elite* (sete ou mais releases por semana), concentrados em projetos que automatizam a publicação a cada merge.

RQ2. Qual o tempo entre um commit e seu respectivo deploy?

Hipótese H2: esperamos lead times da ordem de semanas, e não de horas, classificando a maioria dos repositórios como *Medium* ou *Low*. Como a release é publicada em lotes, um commit espera até a próxima versão para ser entregue. Esperamos ainda que a variante por release (a), baseada no commit mais antigo, seja sistematicamente maior que a variante por commit (b), baseada na mediana de todos os commits: um único commit antigo “esquecido” em uma release eleva muito a variante (a) e pouco afeta a (b).

RQ3. Qual a taxa de falha das mudanças entregues por esses repositórios?

Hipótese H3: para a variante (a), proxy de CI, esperamos uma mediana entre 10% e 25%. Falhas de pipeline são frequentes em projetos ativos por causas que não chegam à produção, como testes instáveis (*flaky*), erros de lint e falhas de infraestrutura. Para a variante (b), proxy de entrega, esperamos valores menores, abaixo de 15%, pois uma release corretiva publicada em até sete dias exige que um defeito tenha sido percebido e corrigido rapidamente. Esperamos também baixa concordância entre as duas variantes, já que elas medem fenômenos diferentes: falha de pipeline e defeito entregue ao usuário.

RQ4. Qual o tempo de recuperação após uma execução de CI/CD com falha?

Hipótese H4: esperamos uma mediana entre uma hora e um dia (faixa *High*). Boa parte das falhas de CI é corrigida rapidamente, com um novo commit ou após uma

falha transitória, mas esperamos uma cauda longa de episódios que duram dias, em workflows menos prioritários, como os de documentação ou de publicação de pacotes. Esperamos uma proporção pequena de episódios censurados, abaixo de 10% por repositório.

RQ5. Repositórios com maior frequência de deploy apresentam maior ou menor taxa de falha?

Hipótese H5: em linha com a afirmação do DORA de que velocidade e estabilidade não são um *trade-off*, esperamos uma correlação de Spearman fraca ($|\rho| < 0,3$) entre a frequência de deploy e o CFR, nas duas variantes. Para o CFR (b), esperamos uma correlação levemente positiva, pois quem publica com mais frequência tem mais oportunidades de seguir uma release com uma correção em até sete dias, o que pode ser um artefato da própria definição, e não um sinal de menor estabilidade.

RQ6. Quais características dos repositórios estão associadas a um melhor desempenho DORA?

Hipótese H6: esperamos que o tipo do projeto e o número de contribuidores sejam os fatores com maior associação. Aplicações, serviços e ferramentas CLI devem publicar com mais frequência e ter lead times menores que bibliotecas e frameworks, que priorizam a estabilidade da API. Repositórios com mais contribuidores devem se recuperar mais rápido de falhas de CI, por terem mais pessoas disponíveis para corrigi-las. Para popularidade e linguagem, esperamos diferenças pequenas ou desprezíveis após a correção de Holm para comparações múltiplas.

RQ7. O quanto a classificação DORA de um repositório depende da definição operacional escolhida?

Hipótese H7: esperamos que a classificação seja sensível à definição: que pelo menos 30% dos repositórios mudem de categoria entre a combinação de referência e as alternativas, com kappa de Cohen ponderado apenas moderado (entre 0,41 e 0,60). Esperamos a maior mudança ao incluir pré-releases ou tags como unidade de deploy, que pode elevar a frequência de deploy de vários repositórios em uma ou mais faixas.

As principais contribuições deste trabalho são: (i) um pipeline reproduzível de mineração das métricas DORA a partir da API do GitHub; (ii) um conjunto de dados com as métricas de mais de 300 repositórios, acompanhado de dicionário de dados; (iii) a validação dos critérios automáticos contra uma amostra rotulada por humanos; e (iv) uma análise de quão robustas são as conclusões frente à escolha da definição operacional.

O restante do artigo está organizado da seguinte forma: a Seção 2 descreve a coleta, as definições operacionais e o protocolo de validação manual; a Seção 3 apresenta os resultados por questão de pesquisa; a Seção 4 compara as hipóteses com os resultados; a Seção 5 discute as ameaças à validade; e a Seção 6 relata a replicação cruzada.

2. Metodologia

3. Resultados

4. Discussão

5. Ameaças à Validade

6. Replicação Cruzada

Disponibilidade

Repositório do grupo: <https://github.com/Lab-Experimentao/Lab03-MineracaoMetricasDora>.

GitHub Projects do grupo: <https://github.com/orgs/Lab-Experimentao/projects/2/views/2>.

Referências

DORA. DORA's software delivery metrics: the four keys. <https://dora.dev/guides/dora-metrics-four-keys/>. Acesso em: out. 2026.

DORA. A history of DORA's software delivery metrics. <https://dora.dev/insights/dora-metrics-history/>. Acesso em: out. 2026.

DORA (2024). Accelerate state of DevOps report. <https://dora.dev/research/>. Acesso em: out. 2026.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution.